

基于 Specialist Router 的 Overcooked 双智能体协作策略研究

更新时间：2026-06-28

摘要

本项目研究两个智能体在 Overcooked 环境中的协作学习问题。我们以 Stable-Baselines3 PPO 为基础算法，通过 PantheonRL simultaneous-agent wrapper 同时训练两个智能体，并以每局交付汤数作为主要评价指标。实验表明，默认 reward shaping 可以让 PPO 在简单地图 simple 上学习到有效协作策略；但纯 sparse reward、zero-shot 跨地图迁移、朴素多地图混训都无法形成可靠的跨地图能力。

在后续阶段，我们转向 single-layout specialist 和 layout router。每张地图训练独立专家，再由 router 按 layout name 选择对应策略。该方法在 simple、random0、random1、unident_s 上获得稳定非零结果。对于最困难的 small_corridor，PPO 从零训练和多种 reward shaping 均失败；通过 scripted full-chain behavior cloning、multi-cycle demonstrations、wait-perturbed demonstrations 以及 checkpoint-selected PPO fine-tuning，最终将该地图提升到 3.00 soups。最终最强 router 在五个 onion layouts 上达到平均 7.98 soups，最低 3.00 soups。

核心结论是：在当前环境栈和训练预算下，最有效的方案不是期待单一 PPO 策略自然泛化到所有地图，而是把跨地图能力建模为 specialist composition / policy selection 问题。同时，partner robustness 和 checkpoint selection 是必须显式评估的关键风险。

1. 问题设置

Overcooked 是一个完全合作式多智能体任务。两个智能体需要在有限步数内分工完成拿洋葱、放锅、等待烹饪、拿盘、取汤、上菜等子任务。每成功交付一份汤得到 sparse reward 20，因此本文使用：

```
soups delivered = sparse reward / 20
```

作为主指标。默认评估设置为 20 个 deterministic episodes，每局 horizon 为 400 steps。

本文关注七个问题：

1. PPO baseline 能否在简单地图上学会合作。
2. Reward shaping 对学习是否必要。
3. 单地图策略能否 zero-shot 泛化到其他地图。
4. 朴素多地图混训能否解决泛化问题。
5. Specialist + router 能否形成更强的实用方案。
6. small_corridor 这类困难地图是否能通过 imitation / curriculum 解决。
7. 自博弈成功是否意味着对不同 partner 鲁棒。

2. 方法

2.1 PPO Baseline

基础算法为 PPO。每个 layout 中训练 ego 和 partner 两个策略，评估时使用 deterministic action。主要脚本如下：

- scripts/train.sh
- scripts/evaluate.sh
- scripts/evaluate_matrix.sh
- scripts/record_demo.sh

主要 baseline 配置为 configs/baseline_simple.json 。

2.2 Reward Shaping 消融

我们比较三种简单地图设置：

Run	设置	目的
no_shaping_simple	关闭 shaping	检验 sparse-only 学习难度
baseline_simple	默认 shaping	建立可靠 PPO baseline
distance_shaping_simple	默认 shaping + distance reward	检验额外距离奖励是否有帮助

2.3 Specialist 与 Router

Zero-shot 和朴素多地图训练失败后，我们将跨地图问题改写为 specialist composition：每张目标地图训练一个 specialist，再由 router 按 layout 选择 run。

Router 相关代码：

- src/overcooked_project/evaluate_router.py
- scripts/evaluate_router.sh
- configs/router_simple_random0.json

该方案不声称单个神经策略具备跨地图泛化能力，而是衡量“专家组合”在当前项目预算下能达到的实用上界。

2.4 Behavior Cloning 与 Small Corridor Curriculum

small_corridor 是项目中最困难的 onion layout。PPO 从零训练、多种结构化 shaping、delivery warm-start PPO 都无法从标准开局完成上菜。因此我们逐步引入监督轨迹：

1. Delivery demos：只学习最后送汤段。
2. Full-chain demos：从标准开局完成一份汤。
3. 3-cycle full-chain demos：连续完成三份汤。
4. Wait-jittered 3-cycle demos：在安全同步点加入随机等待扰动。
5. 从 perturbed BC 初始化 PPO，并选择 25k best checkpoint。

关键脚本：

- scripts/collect_delivery_demos.sh
- scripts/train_delivery_bc.sh
- scripts/train_curriculum.sh

3. 实验结果

3.1 PPO Baseline 与 Reward Shaping

Run	Layout	Mean soups	Mean sparse reward	结论
no_shaping_simple	simple	0.00	0.0	Sparse-only 在当前预算下失败。
baseline_simple	simple	7.50	150.0	默认 shaping 能学到可用协作。
distance_shaping_simple	simple	7.50	150.0	测试的 distance shaping 没有超过默认 shaping。

结论：reward shaping 对 PPO 学习是必要的，但简单叠加距离奖励并不自动提升最终 sparse performance。

3.2 Zero-Shot 与 Multi-Layout 失败

baseline_simple 在 simple 上可达到 7.50 soups，但迁移到 harder layouts 后基本没有 sparse reward。


Layout	Mean soups
simple	7.50
small_corridor	0.00
random0	0.00
random1	0.00
unident_s	0.00 sparse

朴素多地图 curriculum 也没有解决问题，甚至会损伤 simple 上的能力。这说明当前任务的跨地图泛化不能依赖简单训练分布混合。

3.3 Specialist 与 Router

单地图 specialist 可以解决多个困难地图：

Specialist	Layout	Mean soups	Mean sparse reward
curriculum_simple_random0	simple	9.55	191.0
baseline_random0_long_seed52	random0	8.85	177.0
baseline_random1	random1	5.80	116.0
baseline_unident_s	unident_s	12.70	254.0



三组 router 对比如下：

Router	simple	random0	small_corridor	random1	unident_s	Average	Minimum
PPO-only onion router	9.55	8.85	skipped	5.80	12.70	9.23	5.80
With 3-cycle BC small_corridor	9.55	8.85	1.90	5.80	12.70	7.76	1.90
With perturbed BC+PPO small_corridor	9.55	8.85	3.00	5.80	12.70	7.98	3.00

当前最强结果是 checkpoint-selected perturbed BC+PPO small_corridor specialist 加入后的五地图 router，平均 7.98 soups，最低 3.00 soups。

3.4 Small Corridor Case Study



`small_corridor` 的优化过程如下：


Run	Mean soups	Mean sparse reward	解释
baseline_small_corridor	0.00	0.0	PPO 从零失败。
small_corridor_structured_shaping_v3	0.00	0.0	能到 soup pickup, 但不能上菜。
small_corridor_delivery_bc_from_v3 standard start	0.00	0.0	Delivery-only BC 太窄。
small_corridor_full_chain_bc_from_v3	1.00	20.0	一份汤 full-chain BC 成功。
small_corridor_full_chain_3cycle_bc_from_v3	1.90	38.0	多轮 BC 有提升但不稳定。
small_corridor_full_chain_3cycle_jitter3_bc_from_v3	2.50	50.0	等待扰动提升鲁棒性。
small_corridor_full_chain_3cycle_jitter3_role_balanced_bc_from_v3	2.40	48.0	合并 p0/p1 角色数据训练两个模型, 没有超过固定分工 BC。
small_corridor_subtask_router_jitter_bc_delivery	2.60	52.0	soup-held 时切换到 delivery BC, 对 BC-only 有小幅帮助。
small_corridor_subtask_router_best_bc_ppo_delivery	2.45	49.0	同样切换会破坏 checkpoint-selected BC+PPO 闭环。
small_corridor_full_chain_3cycle_jitter3_bc_ppo_finetune best at 25k	3.00	60.0	20/20 局达到 3 soups。
small_corridor_full_chain_3cycle_jitter3_bc_ppo_finetune final 50k	0.85	17.0	过训练后崩溃。

这说明 `small_corridor` 的难点不只是 reward coefficient 不合适, 而是长时序探索和多子任务衔接困难。Scripted demonstrations 提供了可学习的动作链, wait jitter 让 BC 不再只记住精确时钟。简单地把两名玩家的角色数据合并给两个模型并没有继续提升表现, 说明瓶颈不只是固定角色数据量不足。手写 subtask router 可以对 BC-only 末端送餐略微补救, 但会破坏已经 fine-tune 好的 BC+PPO 闭环。PPO fine-tuning 在 25k checkpoint 进一步稳定策略, 但 50k final 崩溃, 说明 checkpoint selection 是必要的。

3.5 Partner Robustness

Partner robustness stress test

Self-play score versus worst held-out partner score



Source: outputs/runs/*/metrics/partner_matrix*.csv

自博弈成功不代表 partner 泛化成功:

Layout / ego	Self-play soups	Held-out partner soups	解释
simple baseline ego	7.50	5.60 with seed11, 0.00 with seed12	简单地图也有 partner overfitting。
random0 long specialists	6.30 to 8.85	1.65 to 7.70	跨 partner 不对称。
random1 specialists	1.50 to 5.80 across tested seeds	0.00 to 1.10 across held-out partners	自博弈成功也可能跨 partner 崩溃。
partner_diversity_random1	2.25 to 4.55 with two training partners	0.45 with held-out seed72, 1.10 with held-out seed73	Seen partners 上更稳，但没有解决真正 held-out 泛化。
partner_diversity_random1_three_partners	0.65 to 4.90 with three training partners	1.00 with held-out seed73	Seen-partner minimum 提高，但四伙伴平均没有超过 two-partner run。
partner_diversity_random1_three_partners_selfplay_mix	0.10 with learned alt.zip	0.05 to 1.85 across four fixed partners	固定 partner + learned partner 混合训练效果更差，是负结果。
partner_conditioned_random1_four_partners	5.60 with copied first partner	0.80 to 1.70 with weaker known partners; 0.00 to 0.05 with unknown seeds 76/77/78 under fixed and inferred ids	显式 partner id 条件化提升已知 partner avg/min，但不泛化到 held-out partners。
partner_conditioned_random1_six_partners_holdout78	0.00 to 2.10 across six training partners	0.00 with held-out seed78 under fixed and inferred ids	单纯扩大 conditioned partner pool 反而降低 seen-partner 稳定性，也没有带来 held-out 泛化。
unident_s specialists	12.60 to 12.70	12.60 to 12.65	两个 seed 间较鲁棒。

因此，报告中不能只展示 self-play 分数。每个声称鲁棒的 specialist 都需要 cross-play 或 held-out partner 证据。

4. Demo 与 Artifact

推荐展示 GIF：

Demo	Path	用途
Default PPO baseline	demo.gif	展示 simple baseline 成功。
Sparse reward failure	demo.gif	展示 sparse-only 失败。
Naive multi-layout failure	simple_demo.gif	展示朴素混训问题。
random0 specialist	random0_long_demo.gif	展示 hard-layout specialist。
random1 specialist	random1_demo.gif	展示另一张 hard layout。
unident_s specialist	unident_s_demo.gif	展示最强 specialist。
Best small_corridor specialist	small_corridor_full_chain_3cycle_jitter3_bc_ppo_best_demo.gif	展示最终 small_corridor 成功。

核心数据路径：

- 完整实验日志： docs/experiment_log.md
- 报告材料： docs/report_materials.md
- 最强 router：
outputs/runs/router_onion_layouts_with_small_corridor_jitter3_bc_ppo/metrics/router_eval.csv
- small_corridor best/final checkpoint：
outputs/runs/small_corridor_full_chain_3cycle_jitter3_bc_ppo_finetune/metrics/train_summary.json
- Partner matrix： outputs/runs/*/metrics/partner_matrix*.csv

5. 局限性

- 当前最强方案是 specialist router，不是单一神经策略的跨地图泛化。
- small_corridor 的成功依赖 scripted demonstrations 和 checkpoint selection，不能表述为 PPO 从零探索成功。
- random1 在 held-out partner 下明显崩溃；两 partner 和三 partner 的 partner-aware training 都只改善部分 seen partners，mixed fixed + learned partner 版本更差；partner-id conditioning 能把四个已知 partner 平均提高到 2.34、最低提高到 0.80，但遇到未知 seed76/77/78 时固定 id 和简单在线 id 推断都仍为 0.00 到 0.05。继续扩大到六个 conditioned training partners 后，训练池平均只有 0.66、最低 0.00，held-out seed78 仍为 0.00。
- small_corridor 的简单 subtask router 和 role-specific router 都不能超过当前 best checkpoint；delivery BC 只对 BC-only 策略有很小救援作用。
- Tomato layouts 当前因 KeyError: 'tomato' 没有纳入主结果，应作为环境栈问题单独说明。
- PPO fine-tuning 可能非单调，最终 checkpoint 不一定代表最佳策略。

6. 结论

本项目展示了一条从基础 PPO baseline 到 specialist router 的完整 MARL 实验链条。默认 shaping 的 PPO 能在 simple 上学到合作，但 sparse-only、zero-shot 和朴素多地图训练都失败。通过训练单地图 specialist 并使用 layout router，我们在多个困难 onion layouts 上获得了稳定表现。对于最困难的 small_corridor，我们通过 full-chain BC、多轮 demonstrations、wait perturbation 和 checkpoint-selected PPO fine-tuning，最终达到 3.00 soups。

因此，本项目的核心结论是：在当前 Overcooked 设置下，跨地图能力更适合通过 specialist composition 和 policy selection 实现；如果进一步追求统一策略或更强泛化，需要引入 layout-conditioned policy、distillation、partner-conditioned policy，或 MAPPO/HAPPO/HARL 式异质多智能体训练。

7. 后续工作

1. 最终提交前按课程模板补充课程、队伍、姓名和学号等元信息。
2. 继续研究 random1 partner robustness；四伙伴 partner-id conditioning 比无条件 partner pool 更好，但 seed76/77/78 fixed-id 与简单 online-id inference probes 仍为 0.00 到 0.05，六伙伴 conditioned pool 也没有改善 held-out seed78。后续需要更强 latent/context partner inference、recurrent/context conditioning 或 HARL/MAPPO/HAPPO 风格算法。
3. 设计 learned option routing 或更结构化的 small_corridor pickup/delivery controller；当前 held-soup 和 role-specific 手写规则都不足以超过 best checkpoint。
4. 尝试 distillation，把 router specialists 蒸馏成统一策略。
5. 单独修复 tomato layout 的 featurizer 问题。