

Overcooked 多智能体协作策略研究

PPO baseline → failure analysis → specialists → layout router

任务设置

- 环境: Overcooked-AI + PantheonRL simultaneous-agent wrapper
- 智能体: 两个 PPO agents, 同时学习合作
- 每局 horizon: 400 steps
- 主指标: `soups delivered = sparse reward / 20`
- 目标: 从 baseline 出发, 构建能覆盖多张 onion layouts 的实用方案

核心问题

1. PPO 能否在简单地图上学会合作?
2. Reward shaping 是否必要?
3. 单地图策略能否 zero-shot 泛化?
4. 多地图混训是否足够?
5. Specialist + router 能否更稳定?
6. `small_corridor` 这种长链条地图怎么处理?
7. 自博弈成功是否等于 partner 鲁棒?

Baseline 结论

Run	Layout	Mean soups	结论
no_shaping_simple	simple	0.00	sparse-only 失败
baseline_simple	simple	7.50	默认 shaping 有效
distance_shaping_simple	simple	7.50	没超过默认 shaping


结论：reward shaping 是必要条件， 但简单加距离奖励不一定提升最终 sparse performance。

泛化失败

- `baseline_simple` 在 `simple` 上达到 7.50 soups。
- 迁移到 `small_corridor`、`random0`、`random1`、`unident_s` 后基本 0 sparse reward。
- 朴素多地图 curriculum 也没有解决问题，甚至损伤 `simple` 能力。

因此，当前阶段不把重点放在“单一 PPO policy 自然泛化”上。


Specialist Router



Router 结果

Router	Average	Minimum	解释
PPO-only onion router	9.23	5.80	强，但跳过 small_corridor
With 3-cycle BC small_corridor	7.76	1.90	五图覆盖，但 small corridor 较弱
With perturbed BC+PPO small_corridor	7.98	3.00	当前最强五图覆盖

Small Corridor 难点




Small Corridor 关键发现

- PPO from scratch: 0 soups
- Structured shaping: 能推进到 soup pickup, 但无法上菜
- Delivery-only BC: 只会最后一段, 标准开局仍失败
- Full-chain BC: 从标准开局做到 1 soup
- 3-cycle BC: 平均 1.90 soups
- Wait-jittered BC: 平均 2.50 soups
- Role-balanced BC: 平均 2.40 soups, 未超过固定分工 BC
- Subtask router: BC-only 到 2.60, 但会把最佳 BC+PPO 降到 2.45
- Perturbed BC + PPO 25k checkpoint: 稳定 3.00 soups
- PPO 50k final: 退化到 0.85 soups

结论: checkpoint selection 是必要的。

Partner Robustness



Source: outputs/runs/*/metrics/partner_matrix*.csv

Partner 结论

- Self-play 分数不能代表真实鲁棒性。
- random1 self-play 有 5.80 soups, 但 held-out partner 几乎归零。
- 两 partner 的 partner_diversity_random1 改善 seen partners, 但 held-out seed72 仍只有 0.45 soups。
- 三 partner 训练把 seen-partner minimum 提到 0.65, 但 held-out seed73 仍只有 1.00 soups。
- 固定三 partner + learned partner 混训平均只有 0.69 soups, 是负结果。
- Partner-id conditioning 提升到 known avg 2.34 / min 0.80, 但 unknown seed76 仍为 0。
- unident_s 在测试 seed 间更稳定。
- 报告中必须区分 self-play success 与 partner robustness。

最终主张

1. PPO + default shaping 能解决 simple 。
2. Sparse-only、zero-shot、naive multi-layout 都失败。
3. Single-layout specialists 能解决多个 hard layouts。
4. Layout router 是当前最强 practical method。
5. small_corridor 需要 scripted BC、perturbation 和 checkpoint selection；简单 role-balanced BC 不够。
6. 后续重点是 stronger partner-conditioned/HARL-style 训练、learned option routing 和统一策略蒸馏。

Demo 顺序

1. `baseline_simple/demo/demo.gif`
2. `no_shaping_simple/demo/demo.gif`
3. `multi_layout_curriculum/demo/simple_demo.gif`
4. `baseline_random0_long/demo/random0_long_demo.gif`
5. `baseline_random1/demo/random1_demo.gif`
6. `baseline_unident_s/demo/unident_s_demo.gif`
7. `small_corridor_full_chain_3cycle_jitter3_bc_ppo_best_demo.gif`

结论

当前项目最有说服力的结果不是“一个 PPO 策略泛化到所有地图”，而是：

baseline works on simple → sparse / zero-shot / multi-layout fail → specialists solve hard layouts → router composes specialists → small corridor needs BC + checkpoint selection

这条链条能诚实解释失败，也能给出清晰改进。